


Регрессия


Постановка задачи регрессии

- Объект описывается набором признаков
- Целевая переменная — числовая величина
- Ошибка модели — это то, насколько предсказанное число отклоняется от наблюдаемого.
- Регрессия — класс задач, а не один алгоритм



Регрессия в общем процессе моделирования

- Исходные данные: объекты, признаки, числовой целевой столбец
- Подготовка: очистка, преобразование, конструирование признаков
- Выбор семейства моделей под тип целевой величины
- Оценка качества по числовым метрикам ошибки



Линейная регрессия как базовая модель

- Линейная модель зависимости целевого признака от набора признаков
- Предсказание: взвешенная сумма признаков плюс смещение
- Веса модели настраиваются по критерию средней квадратичной ошибки
- Веса отражают направление и величину влияния признаков на предсказание

Полиномиальные признаки и нелинейная регрессия

- Расширение пространства признаков полиномиальными преобразованиями
- Линейная модель по весам в расширенном пространстве признаков
- Описание гладких нелинейных зависимостей без смены алгоритма обучения
- Рост числа признаков при увеличении степени полинома и размерности данных

Регуляризация в линейных моделях

- При большом числе признаков линейная модель легко подстраивается под случайный шум
- Регуляризация добавляет к ошибке на данных дополнительный штраф за большие по модулю веса
- Модель выбирает решения с умеренными весами и ведёт себя устойчивее на новых данных
- L2-регуляризация (гребневая регрессия), L1-регуляризация (регрессия Лассо), их комбинации

Гребневая (Ridge), Лассо (Lasso) и Elastic Net

- Гребневая регрессия (Ridge): L2-регуляризация, сглаживание весов
- Регрессия Лассо (Lasso): L1-регуляризация, зануление части весов
- Elastic Net: совместное использование L1 и L2-регуляризации
- Регуляризованные линейные модели уменьшают подгонку под шум и стабилизируют веса

Пошаговая (stepwise) регрессия

- Пошаговая процедура выбора признаков для линейной модели
- Варианты: добавление признаков (forward), удаление признаков (backward)
- На каждом шаге сравниваются модели по выбранному критерию качества
- Плюсы: наглядный процесс, явный список выбранных признаков
- Минусы: жадный перебор, чувствительность к данным, вытесняется регуляризацией и ансамблями

Регрессия на основе опорных векторов (SVR)

- Допуск по ошибке: объекты с $|\text{ошибкой}| \leq \varepsilon$ не влияют на обучение
- Опорные объекты: настройка модели по точкам с $|\text{ошибкой}| > \varepsilon$
- Полезна при сложной зависимости и небольших/средних выборках

Пуассоновская регрессия для счётчиков

- Целевой признак — счётчик событий за интервал $(0, 1, 2, \dots)$
- Модель для среднего числа событий с опорой на распределение Пуассона
- Модель строит линейную зависимость не для самого счётчика, а для логарифма его среднего значения по признакам
- Применение: редкие события, агрегированные по времени, территории, группе пользователей

Порядковая регрессия для упорядоченных уровней

- Целевой признак — упорядоченные уровни (рейтинги, приоритеты, степени тяжести)
- Обычная классификация не учитывает близость уровней
- Модель вводит скрытую числовую шкалу и пороги между уровнями
- Ошибки на соседний и на дальний уровень трактуются по-разному

Деревья решений в задачах регрессии

- Рекурсивное разбиение пространства признаков на области
- Внутренние узлы: условие на признак, листья: числовое предсказание
- Предсказание в листе = среднее целевого признака по обучающим объектам
- Естественное описание пороговых и локальных эффектов без явных преобразований признаков

Ансамбли деревьев в регрессии

- Несколько деревьев решений, обученных с вариациями данных и параметров
- Случайный лес: усреднение предсказаний независимых деревьев
- Градиентный бустинг: последовательное добавление деревьев для исправления ошибок
- Подходят для сложных зависимостей и разнородных признаков

Нейронные сети в задаче регрессии

- Линейная регрессия = нейросеть без скрытых слоёв (один линейный слой)
- Выходной слой выдаёт одно или несколько вещественных значений
- Функции потерь: среднеквадратичная, средняя абсолютная и их варианты
- Применение: сложные зависимости и сложные признаки (последовательности, текст, изображения)

Итоговая «карта методов регрессии»

Линейные модели

- базовая линейная регрессия
- полиномиальные признаки
- регуляризация: Ridge, Lasso, Elastic Net

Нелинейные модели

- регрессия на основе опорных векторов (SVR)
- деревья решений
- ансамбли деревьев (случайный лес, бустинг)

Тип целевого признака

- вещественное число
- счётчик событий
- упорядоченные уровни

Специализированные постановки

- Пуассоновская регрессия (счётчики)
- порядковая регрессия (упорядоченные уровни)

Нейронные сети — регрессия поверх сложных признаков (текст, изображения, последовательности)