


Кластеризация


Зачем нужна кластеризация?

- Группировка объектов без заранее заданных меток
- «Похожие вместе, непохожие — отдельно»
- Примеры: клиенты, тексты, изображения, события



Практические задачи кластеризации

- Сегментация клиентов и пользователей
- Поиск аномалий и подозрительных объектов
- Группировка текстов и документов
- Обработка изображений и сигналов
- Исследование структуры данных



Customer
segmentation


Anomaly
detection

Text and
grouping

Data
structure
exploration

Общая схема методов кластеризации

- Объекты как точки в признаковом пространстве
- Метрика расстояния и мера похожести
- Критерий «хорошего» разбиения
- Основные семейства методов
- Связь предположений и результата




Типичные проблемы кластеризации

- Масштабы признаков и нормализация
- Числовые и категориальные признаки в одном наборе
- Выбросы и шум в данных
- Высокая размерность признакового пространства
- Выбор метрики и настроек алгоритма

Метод k-средних

- Вход: число кластеров k и признаки объектов
- Кластер описывается центром — средним по признакам
- Итерации: распределение объектов $\rightarrow$ пересчёт центров
- Критерий: сумма квадратов расстояний до центров
- Свойства: сходится, но к локальному минимуму, зависит от инициализации



Ограничения k-средних

- Требуется задать число кластеров k
- Ориентирован на «округлые» кластеры похожего размера
- Работает с числовыми признаками и евклидовым расстоянием
- Чувствителен к выбросам и инициализации центров
- Даёт локальный минимум критерия


Варианты k-средних

- k-медиан и k-медоидов: устойчивость к выбросам
- k-modes: кластеризация категориальных признаков
- Смешанные данные и комбинированные расстояния
- Нечёткая кластеризация: fuzzy c-means, fuzzy k-modes


Иерархическая кластеризация

- Иерархия кластеров, а не одно разбиение
- Агломеративный подход (снизу вверх)
- Делящий подход (сверху вниз)

Agglomerative Hierarchical Clustering




Divisive Hierarchical Clustering




Дендрограмма и остовное дерево

- Дендрограмма: дерево слияний кластеров
- «Высота» узла = расстояние между объединяемыми кластерами
- «Разрез» по высоте задаёт число кластеров




Плотностная кластеризация

- Кластер = область повышенной плотности точек
- Локальная плотность через окрестность и число соседей
- Плотные области отделены разрежённым «фоном»
- Точки вне плотных областей считаются шумом
- Примеры: DBSCAN, Mean Shift



DBSCAN: кластеры и шум

- Параметры: радиус ϵ и порог MinPts
- Типы точек: опорные, граничные, шум
- Кластер = область, достижимая по цепочке опорных точек
- Число кластеров не задаётся заранее



Вероятностные модели кластеров и алгоритм EM


- Кластер как компонент смеси распределений
- Мягкая принадлежность объекта к нескольким кластерам
- Скрытые «метки кластера» как ненаблюдаемые переменные
- EM (ожидание–максимизация):
 - шаг ожидания — оценки принадлежностей
 - шаг максимизации — обновление параметров

Оценка качества кластеризации

- Внутренние критерии: компактность и разделённость
- Коэффициент силуэта, индекс Дэвиса–Болдина
- Внешние критерии при наличии эталонных меток
- Визуальный анализ после понижения размерности
- Проверка устойчивости разбиения

Выбор числа кластеров

- Число кластеров = гиперпараметр, который нужно подбирать
- Метод «локтя»: строим график качества от k и ищем точку перегиба
- Силуэты: считаем средний коэффициент для разных k и ищем максимум
- Устойчивость: сравниваем разбиения при разных запусках и подвыборках
- Предметная область: проверяем, есть ли смысл у кластеров для эксперта



Сравнение алгоритмов кластеризации на одних данных

