

Понижение
размерности

Задача понижения размерности

- Меньше признаков при том же числе объектов
- Сохранить структуру данных в пространстве признаков
- В задачах с учителем — сохранить связь с целевой переменной
- Зачем: визуализация, скорость, борьба с переобучением



Два подхода: отбор и построение новых признаков

- Отбор признаков: выбираем подмножество исходных
- Построение новых признаков: считаем комбинации исходных
- Отбор — когда важно сохранить исходные признаки и их смысл
- Новые признаки — когда можно пожертвовать смыслом отдельных признаков ради меньшей размерности и качества моделей

Отбор признаков: общая идея

- Не все признаки одинаково полезны
- Лишние признаки усиливают переобучение и замедляют обучение
- Нужен критерий качества набора признаков
- Полный перебор всех комбинаций практически невозможен



Прямой отбор признаков (forward selection)

- Старт: пустой набор признаков
- На каждом шаге добавляем один новый признак
- Выбор признака по качеству модели на валидации
- Останавливаемся, когда добавление почти не улучшает качество

Обратный отбор признаков (backward elimination)

- Старт: полный набор признаков
- На каждом шаге удаляем наименее полезный признак
- Оценка по качеству модели на валидации
- Отбор подмножества: поиск хорошего набора среди многих комбинаций

Другие методы отбора признаков

- Фильтр-методы: оценивают признаки по отдельности
- Методы-обёртки: отбор через качество выбранной модели
- Встроенные методы: отбор признаков во время обучения модели
- Примеры: L1-регуляризация, деревья решений, ансамбли деревьев

Построение новых признаков: новая система координат

- Вместо отбора признаков строим новые признаки
- Новый признак вычисляется по формуле из исходных признаков
- Переход к новой системе координат в пространстве признаков
- Цель: меньше признаков при сохранении структуры данных и качества моделей



Метод главных компонент (PCA)

- Идея: найти направления максимального разброса данных
- Новые признаки = взвешенные суммы исходных признаков
- Первые компоненты описывают основную изменчивость в данных
- Понижение размерности: оставляем только несколько первых компонент



РСА на практике: сколько компонент оставлять

- Каждая компонента даёт свою долю разброса данных
- Смотрим на долю и накопленную долю объяснённой дисперсии
- Подходы: порог по накопленной доле, «локоть» на графике
- Компромисс: меньше компонент $\leftrightarrow$ меньше потеря информации




Сингулярное разложение матриц (Singular Value Decomposition, SVD)

- SVD раскладывает матрицу признаков на три части
- Одна часть задаёт «базис» по объектам, другая — по признакам
- Диагональные элементы задают «силу» основных направлений
- PCA можно реализовать через SVD центрированной матрицы данных

Регрессия на частичных наименьших квадратах (Partial Least Squares Regression, PLSR)

- PCA учитывает только структуру признаков X
- PLSR строит компоненты с учётом и X , и целевой переменной Y
- Новые признаки: линейные комбинации исходных, связанные с Y
- Полезно при большом числе признаков и сильной связи признаков друг с другом

Нелинейные методы понижения размерности: t-SNE и UMAP



- Задача: понижение размерности ради наглядной визуализации
- t-SNE: старается сохранять локальное соседство объектов
- UMAP: сохраняет локальное соседство и часть глобальной структуры
- Основное применение: 2D/3D-карты данных, разведочный анализ

Применение понижения размерности

- Разведочный анализ данных высокой размерности
- Обучение без учителя: визуализация, кластеры, выбросы
- Обучение с учителем: много признаков, мало объектов, сильная связь признаков
- Понижение размерности как шаг в цепочке обработки данных