

Ансамблевые методы

Зачем нужны ансамбли

- Ансамбль объединяет несколько моделей и даёт одно решение
- Усреднение снижает разброс предсказаний, голосование стабилизирует классификацию
- Выигрыш появляется, когда отдельные модели ошибаются по-разному
- Цена ансамбля — время обучения, время инференса и сложность настройки

Из чего состоит ансамбль

- Базовые алгоритмы обучаются как отдельные модели, обычно простые и быстрые
- Агрегация превращает набор предсказаний в одно решение
 - регрессия: среднее или взвешенное среднее
 - классификация: голосование или усреднение вероятностей
- Разнообразие моделей создают данными, признаками или порядком обучения
- Качество ансамбля оценивают на валидационной выборке тем же способом, что и одиночную модель

Бэггинг (Bagging, Bootstrap Aggregation)

- Для каждой модели формируют свою обучающую выборку бутстрэпом
- Модели обучаются независимо и параллельно
- Итоговое решение получают усреднением или голосованием
- Эффект сильнее для нестабильных алгоритмов, особенно для деревьев
- Бэггинг снижает разброс, но обычно слабо влияет на смещение

Случайный лес

- Бэггинг деревьев решений на бутстрэп-выборках
- В каждом узле дерево выбирает разбиение по случайному подмножеству признаков
- Это снижает сходство деревьев и усиливает эффект усреднения
- Регрессия усреднение прогнозов, классификация усреднение вероятностей
- Параметры число деревьев, ограничения сложности, число признаков в узле, минимальный размер листа

Бустинг

- Модели добавляются последовательно, каждая исправляет текущие ошибки ансамбля
- Базовый алгоритм обычно простое дерево, небольшая глубина
- На каждом шаге добавляется небольшая поправка к общему прогнозу
- Качество задаётся функцией потерь и её параметрами, а не правилами голосования
- Контроль переобучения через скорость обучения, число шагов, раннюю остановку, ограничения дерева

AdaBoost

- Последовательность базовых моделей, каждая обучается с весами объектов
- Веса растут у объектов, где ансамбль ошибается, и падают у остальных
- Итоговое решение — взвешенное голосование базовых моделей
- Чувствителен к выбросам и ошибкам разметки, быстро переобучается при сложных базовых деревьях

Градиентный бустинг

- Ансамбль строится как сумма небольших поправок к прогнозу
- Каждая новая модель обучается на ошибках текущего ансамбля
- Выбор поправки определяется функцией потерь для задачи
- Основные параметры: скорость обучения, число шагов, параметры дерева, подвыборки объектов и признаков
- раннюю остановку

Экстремальный градиентный бустинг (XGBoost)

- Градиентный бустинг на деревьях с регуляризацией и контролем сложности листьев
- Случайность для снижения переобучения подвыборка объектов и признаков
- Обработка пропусков и разреженных признаков прямо внутри обучения
- Оптимизации скорости и памяти параллельное построение, работа с большими данными

Категориальный бустинг (CatBoost, Category Boosting)

- Категориальные признаки кодируются статистиками по целевой переменной без утечки в обучение
- Упорядоченный бустинг снижает смещение, которое появляется, когда модель «подглядывает» в целевую при кодировании
- Симметричные деревья ускоряют обучение и делают поведение модели более предсказуемым
- Минимум предобработки для категориальных и пропусков, удобный базовый выбор для табличных данных

Стекинг (Stacked Generalization, Stacking)

- Обучаем несколько разных моделей первого уровня и собираем их прогнозы как новые признаки
- Модель второго уровня учится по этим прогнозам комбинировать модели и исправлять их типичные ошибки
- Чтобы не было утечки, прогнозы для обучения второго уровня получают на кросс-валидации
- Необходимо контролировать сложность модели второго уровня, иначе она переобучится на прогнозах

Как выбирать ансамбль под задачу

- Бэггинг и случайный лес снижают разброс, выигрывают на шумных признаках
- Бустинги снижают ошибку за счёт последовательных исправлений, требуют контроля переобучения
- Категориальные признаки и пропуски лучше закрывает CatBoost
- Стекинг имеет смысл, когда модели дают разные ошибки и есть строгая схема без утечки